

도메인 지식(SPC)과 생성형 AI(RAG)를 결합한 회전기기 예지보 전 시스템

NASA Bearing Dataset의 데이터 파이프라인부터 실시간 진단 서비스까지



발표자 : 민찬우

전체 시스템 오버뷰

센서부터 조치 가이드까지 4단계 파이프라인 아키텍처



[Feature Controller]

데이터 입력

RMS, Kurtosis, Max Amplitude 등 5 종의 지표를 사용자가 직접 조절합니다



[Engine]

main.py

전처리 + SPC 필터 + AI 추론을 거쳐 설비 상태를 진단합니다.



[Brain]

rag_system.py

Pinecone DB에서 매뉴얼을 검색하고 LLM으로 조치 가이드를 생성합니다.



[View]

dashboard.py

설비 상태, RUL 예측 그래프, 조치 가이드를 실시간으로 시각화합니다.

▪ 시스템 아키텍처 상세

본 하이브리드 AI 예지보전 시스템은 데이터 수집부터 조치 가이드 제공까지의 전 과정을 연결하는 파이프라인 구조를 갖추고 있습니다. 각 모듈은 독립적 기능하면서도 유기적으로 연결되어 효율적인 예지보전 프로세스를 구현합니다.

✓ **SPC 필터:** 3-Sigma 룰로 데이터 이상 징후를 감지하여 AI 모델의 오판을 방지합니다.

✓ **Pinecone DB:** 정비 매뉴얼 텍스트를 임베딩하여 관련 내용을 검색합니다.

✓ **AI 추론:** SVM 모델로 상태 진단, XGBoost 모델로 RUL 예측을 수행합니다.

✓ **LLM 리포트:** 매뉴얼 내용을 컨텍스트로 조치 가이드를 생성합니다.

데이터

VINAYAK TYAGI · UPDATED 6 YEARS AGO


▲ 189 ◀ Code Download

NASA Bearing Dataset

Prognostic Dataset for Predictive/Preventive Maintenance



RMS Trend of All 4 Bearings



| | Bearing 1 | Bearing 2 | Bearing 3 | Bearing 4 |
|---|-----------|-----------|-----------|-----------|
| 0 | -0.049 | -0.071 | -0.132 | -0.010 |
| 1 | -0.042 | -0.073 | -0.007 | -0.105 |
| 2 | 0.015 | 0.000 | 0.007 | 0.000 |
| 3 | -0.051 | 0.020 | -0.002 | 0.100 |
| 4 | -0.107 | 0.010 | 0.127 | 0.054 |

1. 데이터셋


- 출처 : NASA IMS Bearing Dataset (Set No.2)
- 구성: 4개의 베어링 진동 센서 데이터
- 기간: 약 7일간 연속 가동 (10분 간격 측정)

2. 분석

- Bearing 1 (Target)
 - 종료 시점 0.45 이상 급증 → 명확한 고장 패턴 확인.
 - 전형적인 Run-to-Failure (가동 후 파괴) 데이터.
- Bearing 2, 3, 4 (Noise)
 - 유의미한 파괴 패턴 없음.
 - 후반부 진동 상승은 Bearing 1의 진동 전이로 인한 공진 현상으로 판단.

Target : Bearing 1

학습 데이터의 품질 확보를 위해 Bearing 1 단독 사용



1. 신호 처리

- **Time Domain** (상단 파란색)
 - 원본 진동 신호(Raw Signal)
 - 노이즈가 섞여 있어 고장 시점이나 원인을 특정하기 어려움
- **Frequency Domain** (하단 빨간색)
 - FFT(Fast Fourier Transform) 알고리즘 적용
 - 시간 영역 데이터를 주파수 영역으로 변환하여 고장 특성 추출

2. Bearing 1 선정

- 고장 주파수 식별
 - FFT 분석 결과, 특정 주파수 대역에서 뚜렷한 피크 관측
 - 이는 베어링 외륜(Outer Race) 결함 시 발생하는 고유 주파수와 일치

* 학습 데이터 적합성

- 명확한 고장 시그널을 보유하고 있어, AI 모델이 고장의 특징을 학습하기에 최적의 데이터로 판단

데이터 전처리 및 학습 데이터셋 구축


통계적 특징 추출부터 임계값 설정을 통한 라벨링까지

Step 1

| | filename | RMS | Std_Dev | Max_Amp | Kurtosis | Skewness |
|-----|---------------------|----------|----------|---------|-----------|-----------|
| 0 | 2004.02.12.10.32.39 | 0.074179 | 0.073475 | 0.454 | 0.628763 | 0.083993 |
| 1 | 2004.02.12.10.42.39 | 0.075382 | 0.075338 | 0.388 | 0.648291 | 0.052142 |
| 2 | 2004.02.12.10.52.39 | 0.076230 | 0.076189 | 0.503 | 0.513475 | 0.032808 |
| 3 | 2004.02.12.11.02.39 | 0.078724 | 0.078691 | 0.608 | 1.157953 | 0.041486 |
| 4 | 2004.02.12.11.12.39 | 0.078474 | 0.078437 | 0.391 | 0.603177 | 0.028224 |
| | filename | RMS | Std_Dev | Max_Amp | Kurtosis | Skewness |
| 979 | 2004.02.19.05.42.39 | 0.725001 | 0.724996 | 5.000 | 12.577705 | -0.510556 |
| 980 | 2004.02.19.05.52.39 | 0.462012 | 0.461990 | 2.881 | 3.759972 | -0.325368 |
| 981 | 2004.02.19.06.02.39 | 0.483835 | 0.483832 | 3.696 | 4.891755 | -0.377095 |
| 982 | 2004.02.19.06.12.39 | 0.002103 | 0.000987 | 0.005 | 3.637513 | 0.579698 |
| 983 | 2004.02.19.06.22.39 | 0.001533 | 0.001000 | 0.005 | -1.609774 | 0.317032 |

Step 2

Bearing Degradation Trend (RMS)



Step 1. 특징 추출

- 원본 파형에서 RMS, Kurtosis, Skewness 등 주요 통계 지표 추출
- 고차원 시계열 데이터를 학습에 효율적인 형태로 압축 및 요약

Step 2. 데이터 시각화 및 기준 설정

- 전체 RMS Trend 시각화를 통해 베어링의 상태 변화 분석
- 변곡점을 기준으로 Normal / Warning / Failure 구간 정의

Step 3. 데이터 라벨링

- 정의된 구간에 따라 Class Label (0, 1, 2) 부여
- 시점 기반의 RUL(잔존 수명) 계산 및 정답지 생성

Step 3

상위 5개 데이터 미리보기 :

| | filename | RMS | Std_Dev | Max_Amp | Kurtosis | Skewness | Label | RUL |
|---|---------------------|----------|----------|---------|----------|----------|-------|-----|
| 0 | 2004.02.12.10.32.39 | 0.074179 | 0.073475 | 0.454 | 0.628763 | 0.083993 | 0 | 983 |
| 1 | 2004.02.12.10.42.39 | 0.075382 | 0.075338 | 0.388 | 0.648291 | 0.052142 | 0 | 982 |
| 2 | 2004.02.12.10.52.39 | 0.076230 | 0.076189 | 0.503 | 0.513475 | 0.032808 | 0 | 981 |
| 3 | 2004.02.12.11.02.39 | 0.078724 | 0.078691 | 0.608 | 1.157953 | 0.041486 | 0 | 980 |
| 4 | 2004.02.12.11.12.39 | 0.078474 | 0.078437 | 0.391 | 0.603177 | 0.028224 | 0 | 979 |

AI 모델링 및 성능 검증

SVM을 활용한 상태 진단과 XGBoost를 활용한 잔존 수명 예측의 이원화 접근



SVM 상태 분류 모델

| 모델 정확도 : 92.89% | | | | |
|-----------------|-----------|--------|----------|---------|
| 상세 리포트 : | | | | |
| | precision | recall | f1-score | support |
| 0 | 0.97 | 1.00 | 0.99 | 106 |
| 1 | 0.74 | 0.91 | 0.82 | 34 |
| 2 | 1.00 | 0.81 | 0.89 | 57 |
| accuracy | | | 0.93 | 197 |
| macro avg | 0.90 | 0.91 | 0.90 | 197 |
| weighted avg | 0.94 | 0.93 | 0.93 | 197 |

알고리즘: Support Vector Machine (SVM)

목적 : 베어링의 현재 상태를 3단계(0: 정상, 1: 주의, 2: 위험)로 실시간 분류

입력 변수 : RMS, Kurtosis, Skewness, Std_Dev, Max_Amp

성능 분석 : 전체 정확도 (Accuracy): 92.89% 달성

<클래스별 성능>


- 정상(0) : 정밀도(Precision) 0.97, 재현율(Recall) 1.00으로

오탐지 최소화

- 위험(2) : 정밀도 1.00을 기록하여, 모델이 '위험'이라고 판단했을 때 실제 고장일 확률이 100%임



XGBoost 수명 예측 모델



알고리즘: XGBoost Regressor (Extreme Gradient Boosting)

목적 : 베어링의 파괴 시점까지 남은 시간(RUL)을 회귀 예측

학습 데이터 : NASA Bearing Dataset의 Run-to-Failure 전 주기 데이터

성능 분석 : 설명력 (R2 Score): 0.80 (변동성의 80%를 모델이 설명함)

오차 범위 (RMSE) : 약 118.01 포인트

<그래프 해석>


- 검은색 점선(실제값)의 복잡한 등락 패턴을 빨간색

실선(예측값)이 매우 유사하게 추종함

- 단순 선형 감소가 아닌, 센서 데이터의 비선형적인 노화 패턴을 효과적으로 학습했음을 확인

하이브리드 진단 및 제어 로직

통계적 공정 관리(SPC)와 AI 모델의 상호 보완을 통한 오진 방지



1. 이중 안전장치

1차 필터 (SPC): 데이터 분포 기반의 3-Sigma 임계값(0.18g)을 적용. 진동이 통계적 유의수준을 넘지 않으면 AI의 오판을 사전 차단.
2차 정밀 진단 : 필터를 통과한 '주의' 구간 데이터만 SVM 모델이 정밀 분석하여 상태 판정.

2. 물리적 예외 처리

- 충격 감지 : 진동이 낮아도, 초기 결합의 신호인 첨도(Kurtosis > 5.0)가 높으면 즉시 위험으로 강제 경상.


3. 예측 신뢰성 확보

- Max Horizon 제약: 학습되지 않은 미래 시점 예측을 방지하기 위해, 정상 구간에서는 RUL을 984시간으로 고정하여 신뢰도 확보.

생성형 AI 기 조치 반시스템 (RAG)

통계적 특징 추출부터 임계값 설정을 통한 라벨링까지

생성형 AI 기반 조치 시스템 (RAG) 작동 원리



Pinecone (Vector DB) : 수천 페이지의 매뉴얼에서 초고속 의미 검색 가능

Groq Llama-3 (LLM Engine) : 빠른 추론 속도로 실시간 현장 대응에 최적화

Google Embedding : 단순 키워드 매칭이 아닌, 문맥을 이해하는 고품질 벡터 변환 수행

RAG 시스템 도입의 3대 핵심 이점

1. 신뢰성 : 데이터 기반의 정밀 진단
 - manual.txt의 구체적 수치(예: RMS 2.8, Kurtosis 4.5)를 근거로 답변하여 LLM의 환각 현상(Hallucination)을 원천 차단합니다.
2. 전문성 : 현장 맞춤형 솔루션 제공
 - 일반 AI가 모르는 특정 설비 및 부품(SKF 6205 베어링)에 최적화된 "M12 볼트 점검", "전용 그리스 보충" 등 실질적 지침을 제공합니다.
3. 효율성 : 실시간 지식 업데이트
 - 거대 모델의 재학습 없이 Pinecone DB에 최신 지침을 업로드하는 것만으로 시스템을 즉시 업데이트할 수 있어 유지보수 비용을 획기적으로 절감합니다.

시스템 구현



1. 특징량 데이터 생성

Data Simulator

NASA IMS 데이터셋에서 추출된 핵심 지표를 1초 단위로 API 서버에 공급합니다.

- 통계적 특징 추출: RMS(진동 에너지), Kurtosis(충격 도) 등 5종 특징량 산출



2. FastAPI 서버

Backend

main.py 스크립트가 백엔드 서버로 동작하며, 데이터를 실시간으로 처리합니다.

- 전처리 > SPC 필터링 > AI 모델 추론
- SVM: 상태 진단 / XGBoost: RUL 예측



3. Streamlit

Frontend


FastAPI로부터 전달받은 분석 결과를 실시간으로 시각화하고 사용자 조치를 유도합니다.

- 진동 추세 및 RUL 예측 결과의 실시간 그래프 렌더링
- RAG 시스템이 생성한 정비 가이드를 가독성 있게 표시

데이터 흐름

특징량 데이터 → 전처리 → SPC 필터 → AI 추론 → RAG 시스템 → 조치 가이드

시연 영상



감사합니다